Московский государственный технический университет им. Н. Э. Баумана Факультет «Информатика и системы управления»

Кафедра «Системы обработки информации и управления» Курс «Технологии машинного обучения»

> Отчет по рубежному контролю №2 Технологии использования и оценки моделей машинного обучения

Группа: ИУ5-62Б

Студент: Селедкина А.С.

Преподаватель: Гапанюк Ю.Е.

Вариант 15

Описание задания

Необходимо решить задачу классификации текстов на основе любого выбранного Вами датасета (кроме примера, который рассматривался в лекции). Классификация может быть бинарной или многоклассовой. Целевой признак из выбранного Вами датасета может иметь любой физический смысл, примером является задача анализа тональности текста. Необходимо сформировать признаки на основе CountVectorizer или TfidfVectorizer.

В качестве классификаторов необходимо использовать два классификатора, не относящихся к наивным Байесовским методам (например, LogisticRegression, LinearSVC), а также Multinomial Naive Bayes (MNB), Complement Naive Bayes (CNB), Bernoulli Naive Bayes.

Для каждого метода необходимо оценить качество классификации с помощью хотя бы одной метрики качества классификации (например, Accuracy).

Сделать выводы о том, какой классификатор осуществляет более качественную классификацию на Вашем наборе данных.

Текст программы и примеры выполнения

Будем использовать датасет, содержащий отзывы на отели и оценку их тональности (happy — положительный, not happy — отрицательный): https://www.kaggle.com/harmanpreet93/hotelreviews.

```
import numpy as np
import pandas as pd
from typing import Dict, Tuple
from sklearn.feature_extraction.text import CountVectorizer, TfidfVectorizer
from sklearn.naive_bayes import GaussianNB, MultinomialNB, ComplementNB, BernoulliNB
from sklearn.model_selection import train_test_split
from sklearn.neighbors import KNeighborsRegressor, KNeighborsClassifier
from sklearn.linear_model import LogisticRegression
from sklearn.metrics import accuracy_score, balanced_accuracy_score
from sklearn.pipeline import Pipeline
from sklearn.svm import SVC, NuSVC, LinearSVC, OneClassSVM, SVR, NuSVR, LinearSVR
import matplotlib.pyplot as plt
%matplotlib inline
```


```
data = pd.read_csv('data/hotel-reviews.csv')
data.head()
```

	User_ID	Description	Browser_Used	Device_Used	Is_Response
0	id10326	The room was kind of clean but had a VERY stro	Edge	Mobile	not happy
1	id10327	I stayed at the Crown Plaza April April	Internet Explorer	Mobile	not happy
2	id10328	I booked this hotel through Hotwire at the low	Mozilla	Tablet	not happy
3	id10329	Stayed here with husband and sons on the way $t\dots$	InternetExplorer	Desktop	happy
4	id10330	My girlfriends and I stayed here to celebrate	Edge	Tablet	not happy

data.shape

(38932, 5)

```
# Распределение классов целевого признака plt.hist(data['Is_Response']) plt.show()
```



Формирование признаков

```
# Сформируем общий словарь для обучения моделей из обучающей и тестовой выборки vocab list = data['Description'].tolist() vocab_list[1:3]
```

["I stayed at the Crown Plaza April -- - April --, ----. The staff was friendly and attentive. The elevators are t iny (about -' by -'). The food in the restaurant was delicious but priced a little on the high side. Of course thi s is Washington DC. There is no pool and little for children to do. My room on the fifth floor had two comfortable beds and plenty of space for one person. The TV is a little small by todays standards with a limited number of cha nnels. There was a small bit of mold in the bathtub area that could have been removed with a little bleach. It app eared the carpets were not vacummed every day. I reported a light bulb was burned out. It was never replaced. Ice machines are on the odd numbered floors, but the one on my floor did not work. I encountered some staff in the ele vator one evening and I mentioned the ice machine to them. Severel hours later a maid appeared at my door with ice and two mints. I'm not sure how they knew what room I was in. That was a little unnerving! I would stay here again for business, but would not come here on vacation.",

```
vocab_vect = CountVectorizer()
vocab_vect.fit(vocab_list)
corpus_vocab = vocab_vect.vocabulary_
print('Количество сформированных признаков - {}'.format(len(corpus_vocab)))
```

Количество сформированных признаков - 46016

```
# Первые 10 признаков
for i in list(corpus_vocab)[0:9]:
    print('{}={}'.format(i, corpus_vocab[i]))
```

the=40646 room=34587 was=44401 kind=22449 of=27927 clean=7665 but=5772 had=18401 very=43761

Решение задачи анализа тональности

```
def accuracy score for classes(
    y true: np.ndarray,
    y_pred: np.ndarray) -> Dict[int, float]:
    Вычисление метрики accuracy для каждого класса
    y true - истинные значения классов
    y pred - предсказанные значения классов
    Возвращает словарь: ключ - метка класса,
    значение - Accuracy для данного класса
    # Для удобства фильтрации сформируем Pandas DataFrame
    d = {'t': y_true, 'p': y_pred}
    df = pd.DataFrame(data=d)
    # Метки классов
    classes = np.unique(y true)
    # Результирующий словарь
    res = dict()
    # Перебор меток классов
    for c in classes:
        # отфильтруем данные, которые соответствуют
        # текущей метке класса в истинных значениях
        temp data flt = df[df['t']==c]
        # расчет ассигасу для заданной метки класса
        temp acc = accuracy score(
            temp data flt['t'].values,
            temp data flt['p'].values)
        # сохранение результата в словарь
        res[c] = temp acc
    return res
def print accuracy score for classes(
    y true: np.ndarray,
    y_pred: np.ndarray):
    Вывод метрики ассигасу для каждого класса
    accs = accuracy score for classes(y true, y pred)
    if len(accs)>0:
        print('Merka \t Accuracy')
    for i in accs:
        print('{} \t {}'.format(i, accs[i]))
def sentiment(v, c):
    model = Pipeline(
         [("vectorizer", v),
          ("classifier", c)])
    model.fit(x train, y train)
    y pred = model.predict(x test)
    print accuracy score for classes(y test, y pred)
sentiment(CountVectorizer(), KNeighborsClassifier())
Метка
          Accuracy
          0.9407025053506232
happy
not happy
                  0.27535456248327533
```

sentiment(TfidfVectorizer(), LinearSVC())

Метка Ассигасу

happy 0.9223215409794788

not happy 0.7923468022477923

sentiment(CountVectorizer(), MultinomialNB())

Метка Accuracy

happy 0.9143900289563137

not happy 0.7511372758897511

sentiment(TfidfVectorizer(), MultinomialNB())

Метка Accuracy

happy 0.9925720760417978

not happy 0.36954776558736957

sentiment(CountVectorizer(), ComplementNB())

Метка Ассигасу

happy 0.9035628855596123

not happy 0.7647845865667647

sentiment(TfidfVectorizer(), ComplementNB())

Метка Accuracy

happy 0.9714213773133576

not happy 0.5731870484345731

sentiment(CountVectorizer(binary=True), BernoulliNB())

Метка Ассигасу

happy 0.857736371647992

not happy 0.6165373294086165

sentiment(TfidfVectorizer(binary=True), BernoulliNB())

Метка Accuracy

happy 0.857736371647992

not happy 0.6165373294086165

На выбранном наборе данных наиболее качественную классификацию осуществили LinearSVC, MultinomialNB и ComplementNB.